

پرسش و پاسخ تقویت‌شده با بازیابی (RAG) با استفاده از مدل‌های زبانی کوچک

سوال ۱

طراحی یک دستیار متنی

مسئله: سامانه‌ای طراحی کنید که با دریافت یک پرسش زبانی، ابتدا اسناد مرتبط را از یک مجموعه‌ی کوچک بازیابی کرده و سپس با استفاده از یک مدل زبانی کوچک، پاسخ نهایی را تولید نماید.

مجموعه داده:

در این تمرین، از مجموعه داده‌ی استاندارد WikiQA استفاده می‌شود. این مجموعه داده شامل پرسش-پاسخ‌های متنی مبتنی بر اسناد Wikipedia است و شامل متن پرسش، پاسخ مرجع و جملات کاندید می‌شود. برای دسترسی به این کتابخانه می‌توانید از ابزار huggingface-cli استفاده کنید. برای دسترسی به اطلاعات این مجموعه داده، لینک زیر را بررسی کنید.

https://huggingface.co/datasets/microsoft/wiki_qa

۱ - پیاده‌سازی سامانه پایه RAG:

یک سامانه‌ی RAG شامل اجزای زیر پیاده‌سازی کنید:

– مدل تعبیه‌ساز متنی مبتنی بر Transformer (مانند MiniLM یا E5)

– ایندکس‌گذاری اسناد با استفاده از FAISS

– یک مدل زبانی کوچک برای تولید پاسخ (مانند FLAN-T5)

معماری کلی سامانه باید شامل مراحل زیر باشد:

۱ - دریافت پرسش

۲ - محاسبه Embedding پرسش

۳ - بازیابی k سند برتر

۴ - الحاق اسناد بازیابی شده به Prompt

۵ - تولید پاسخ نهایی

۲ - تحلیل مازول تعبیه سازی متنی:

اثر انتخاب مدل تعبیه ساز را بررسی نمایید:

- مقایسه حداقل دو مدل Embedding مبتنی بر Transformer

- بررسی تاثیر اندازه Embedding

- تحلیل کیفی اسناد بازیابی شده

معیار اصلی در این بخش:

- Recall@k

۳ - مقایسه مدل های زبانی کوچک (SLM):

در این بخش، عملکرد سامانه ی RAG را با استفاده از سه مدل زبانی کوچک زیر مقایسه نمایید:

- flan-t5-small

- t5-small

- distilgpt2

برای هر مدل:

- کیفیت پاسخ نهایی ارزیابی شود.

- زمان پاسخ گویی روی CPU گزارش گردد.

- تفاوت های سبکی و مفهومی پاسخ ها تحلیل شود.

۴ - افزودن تنظیم دقیق سبک وزن (LoRA / PEFT):

بهترین مدل SLM را از سوال قبلی انتخاب کرده و آن را با استفاده از تکنیک های تنظیم دقیق سبک وزن^۱ روی مجموعه داده، مجددا آموزش دهید. تمام تصمیماتی که در طراحی روش تنظیم دقیق وزن ها انجام داده اید را در فایل گزارش خود ذکر کرده و دلیل هر تصمیم را توضیح دهید. با اجرای مجدد ارزیابی روی مدل، تاثیر این تصمیمات را بر عملکرد مدل شرح دهید (یک بار به

^۱Parameter-Efficient Fine-Tuning

تفکیک هر تصمیم و یک بار با در نظر گرفتن تمام تصمیمات). توجه نمایید برای صرفه جویی در زمان می‌توانید بخش کوچکی از مجموعه داده (بین ۱۰۰ تا ۵۰۰ پرسش-پاسخ) را در این مرحله استفاده نمایید.

۵ - تحلیل حساسیت پارامترها:

اثر تغییر پارامترهای زیر را بررسی نمایید:

– تعداد اسناد بازیابی شده (k)

– طول Prompt

– دمای تولید (Temperature)

نتایج به صورت جدول یا نمودار ارائه شوند.

۶ - تحلیل مفهومی: با توجه به آزمایشات انجام شده، تحلیل خود را روی موارد زیر در فایل گزارش ذکر کنید.

– نقش کیفیت Embedding در معماری RAG

– چالش‌های اجرای RAG روی CPU

– مسیرهای بهبود سامانه

۱ - پیاده‌سازی با Python و PyTorch انجام شود.

۲ - استفاده از GPU مجاز نیست.

۳ - کتابخانه‌های transformers، sentence-transformers و peft مجاز هستند.

۴ - گزارش نهایی شامل تحلیل، جدول و نمودار باشد.

۵ - فایل نهایی با نام StudentID_HW05.zip ارسال شود.

۶ - هرگونه کپی‌برداری منجر به حذف کل نمره خواهد شد.